



# Klasifikácia pľúcneho dýchania

Roman Dzhulai, Ivan Tkachenko  
Nikita Pohorilyi, Dmytro Varich,  
Dmytro Marchuk



## O našom tíme

**Ing. Maroš Hliboký**

Mentor

**Roman Dzhulai**

- Systém pre pohodlnú tvorbu, tréovanie a testovanie modelov
- Dokumentácia
- Redaktor článku
- Model s RAFT a model s reziduálnymi blokmi

**Ivan Tkachenko**

- Vykonávanie, popisovanie experimentov a testovanie modelov
- Pomoc s vývojom modelov
- Redaktor článku

**Nikita Pohorilyi**

- Teoretický popis riešenia, technológií a vyhľadávanie riešení
- Redaktor článku a prezentácie

**Dmytro Varich**

- Analýza a popis datasetu a zodpovedný za medicínske technológie
- Redaktor článku a prezentácie

**Dmytro Marchuk**

- Vývoj a testovanie rekurentného modelu
- Počiatočná úprava datasetu

# Čo je cieľom výskumu našej práce?

Cieľom tejto práce o klasifikácii dýchania pľúc bolo vyvinúť účinný systém, ktorý by na základe analýzy ultrazvukových údajov dokázal presne a spoľahlivo zistiť **prítomnosť** alebo **neprítomnosť** skĺznutia pľúc (lung sliding).



**Pneumotorax** nastáva v prípade, ak sa do pleurálnej dutiny hrudníka dostane vzduch. Nahromadenie a zvýšený tlak vzduchu spôsobí kolaps pľúc, poruchu dýchania a cirkulácie krvi.



# Dataset na detekciu **prítomnosti** alebo **neprítomnosti** klzkosti pľúc

## Ultrazvukové videá

171 ultrazvukových videí pľúcnych vyšetrení od pacientov.

## Charakteristiky snímok

Každé video obsahuje 20 až približne 900 snímok v odtieňoch sivej.

## Rozdelenie dát

Pre experimenty sme používali 60% trénovacie dáta, 20% validačné dáta a 20% testovacie dáta. Pre finálne testovanie modelov sme používali 25% testovacie dáta a 75% trénovacie dáta.

## Lung sliding present

Indikuje bežný pohyb pľúc počas dýchania. Obsahuje 32 videí.

## Lung sliding absent

Indikuje absenciu pohybu pľúc počas dýchania, čo môže predstavovať riziko pre pacienta. Obsahuje 139 videí.



ls\_p



ls\_a



# Predspracovanie údajov

## 1 Konvertovanie triednych značiek

Značky tried `ls_p` a `ls_a` boli prevedené na číselné hodnoty `0` a `1`, model mohol s nimi pracovať.

## 2 Výber dát

Pri výbere údajov sme mali možnosť obmedziť veľkosť výberu alebo vybrať konkrétnu časť pôvodného datasetu.

## 3 Rozdelenie dát

Rozdelenie údajov na trénovaciu, validačnú a testovaciu vzorku za účelom zlepšenia výkonnosti modelu.

## 4 Vyváženie tried

Vyváženia tried v trénovacej vzorke slúži na dosiahnutie rovnováhy medzi počtom príkladov rôznych tried.

## 5 Výpočet pomerov medzi triedami

Výpočet pomerov medzi triedami v rôznych datasetov na vyhodnotenie vyváženosti dát.

# O technológiách CNN a Optical Flow



## Konvolučná neurónová sieť

- Špecializuje sa na spracovanie údajov s priestorovou štruktúrou.
- Efektívna extrakcia príznakov a analýza priestorových štruktúr v obrazoch.

## Vlastnosti

- **Konvergentné vrstvy:** extrakcia funkcií zo vstupných údajov.
- **Vrstvy poolingu:** zníženie dimenzionality údajov pri zachovaní dôležitých vlastností.
- **Plne prepojené vrstvy:** klasifikácia na základe extrahovaných vlastností.

## Optical Flow

- Sa používa na analýzu zmien stavu objektu na obrázku.
- Využívajú lokálne gradienty intenzity pixelov na výpočet pohybu medzi snímkami.

## Vlastnosti

- Predpokladáme, že pohyb objektov v sekvencii je spojitý v čase.
- Citlivosť na zmeny jasu v snímkach.
- Zohľadňuje pohyb na úrovni pixelov.

# Použité technológie

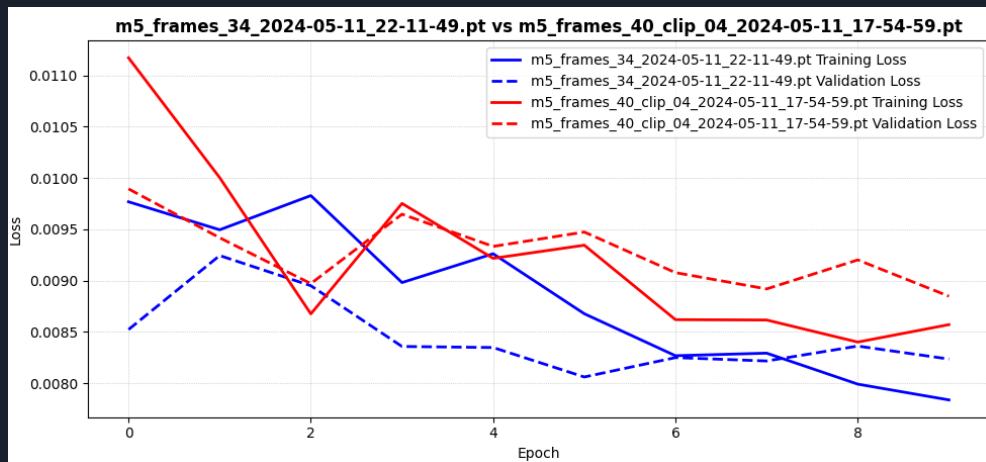
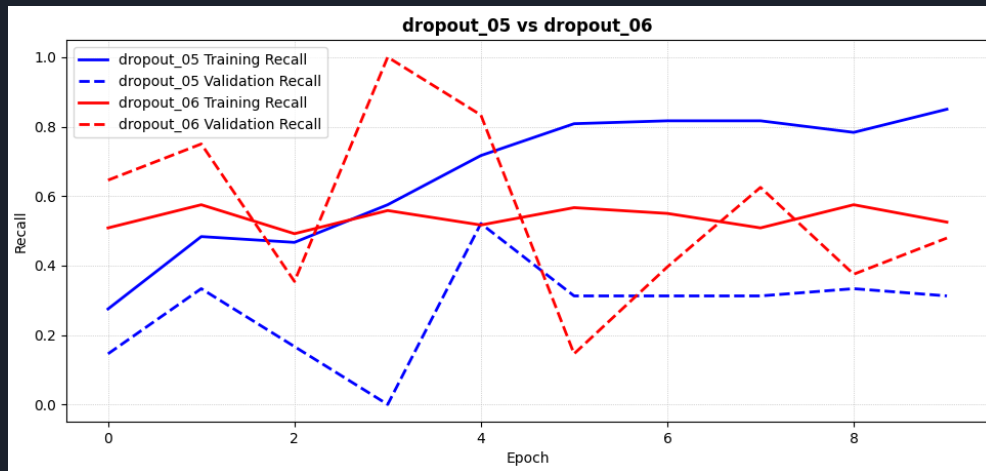
- 3D Convolution
- Residual Units
- Optical Flow
- Augmentation
- Focal Loss Function
- Adam Optimizer
- Channel-Wise Normalization
- Weight Decay
- Batch Normalization
- Gradient Clipping
- Learning Rate Scheduler



# Modely a experimenty

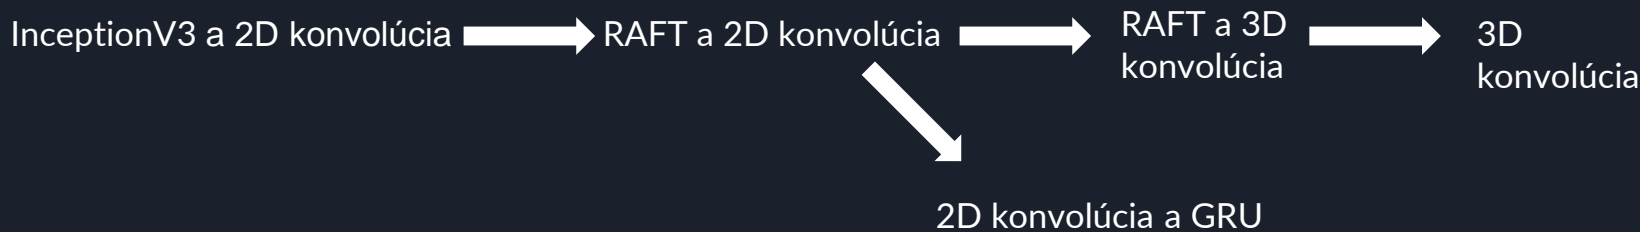
Experimentovali sme najmä s:

- Rôzne architektúry modelov
- Technológie
- Úpravy datasetu
- Hyperparametre





# Ako sme začali a aké architektúry sme skúšali

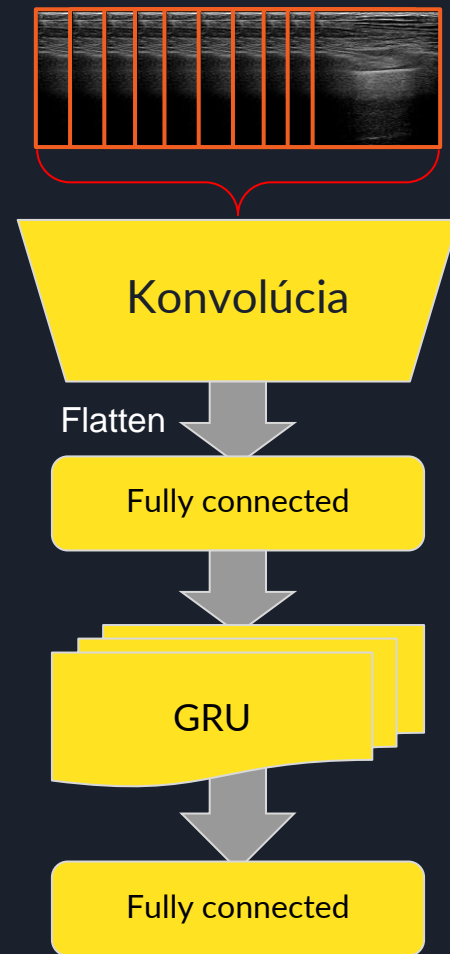
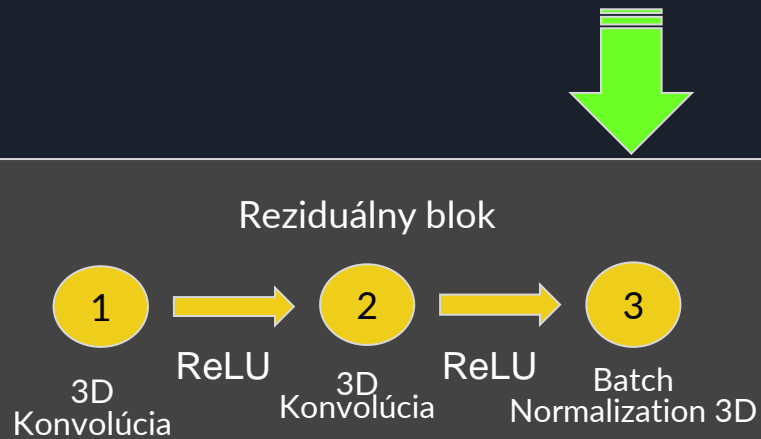
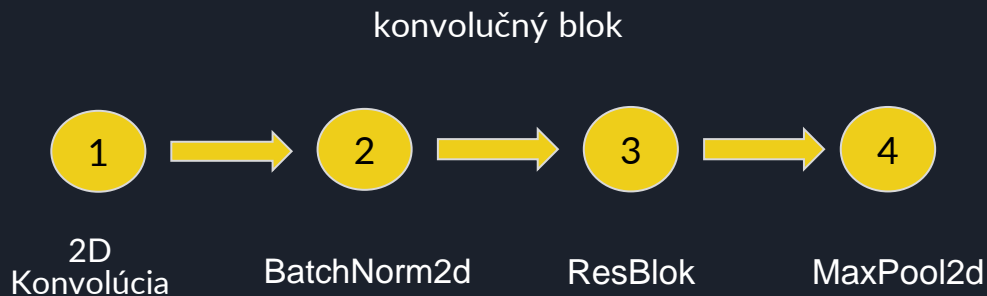


Inception v3 - konvolučná neurónová sieť na pomoc pri analýze obrazu a detekcii objektov.

RAFT (Recurrent All-Pairs Field Transforms) - architektúra hlbkej siete pre extrakciu optical flow.

GRUs (Gated recurrent units) - sú hradlovým mechanizmom v rekurentných neurónových sieťach.

# Rekurentný konvolučný model



# Experimenty s rekurentným konvolučným modelom



Model využíva GRU.

Rôzne architektúry konvolúcie.


Balanced mini-batch training.

Prerozdelenie datasetu.

Veľký problém s overfittingom.



# Model s RAFT



Hybridný model, ktorý používa RAFT, ako extractor optical flow, a 32x32 videí.

# Experimenty s RAFTom

Flow step hyperparameter.

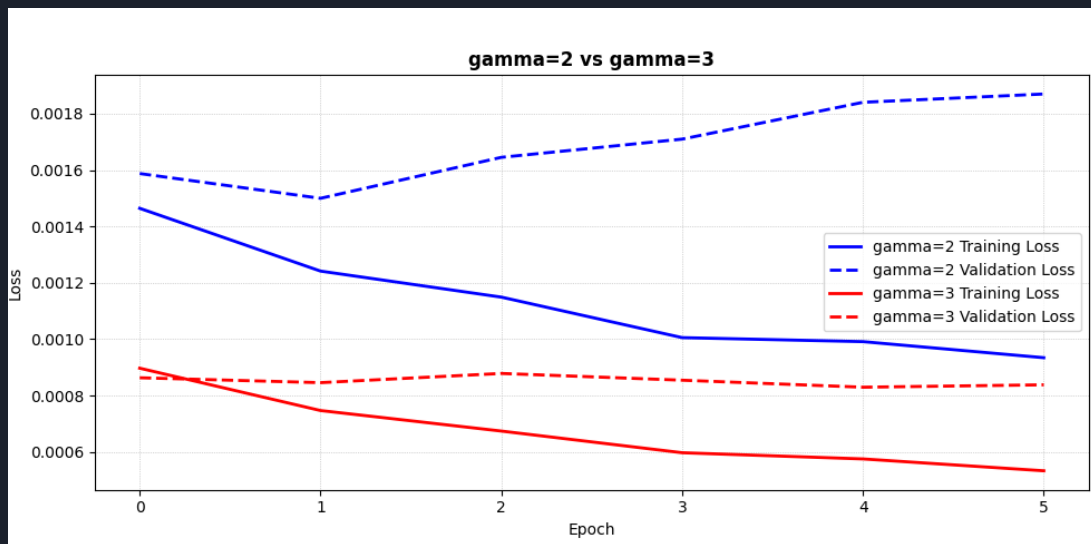
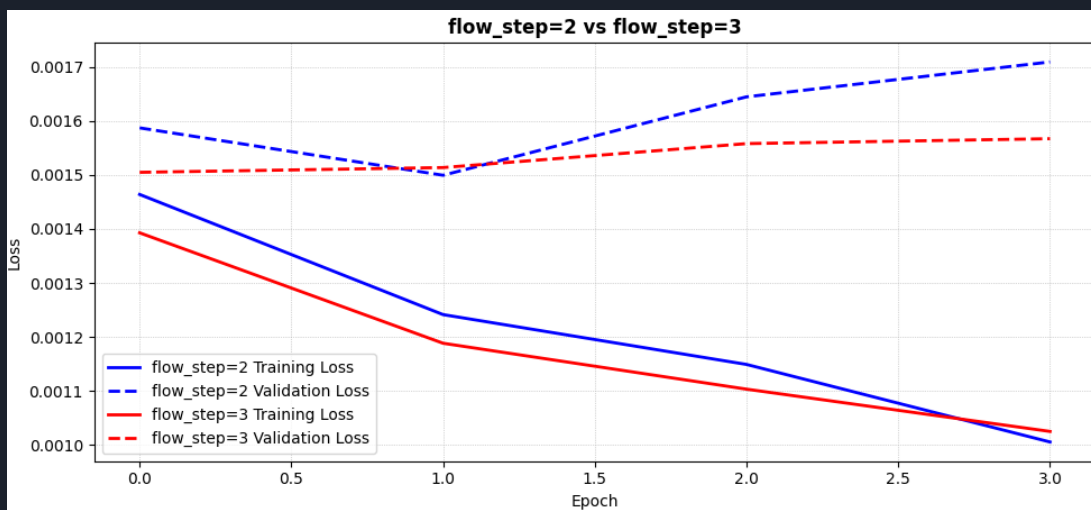
Najlepšie kroky sú 1, 2 a 3.

Rýchle pretrénovanie.

Gamma hyperparameter.

Najlepšia gamma bola 2 a 3.

S týmto modelom sme nedosiahli uspokojivé výsledky.



# Finálny model




## Augmentácia:

- zmena veľkosti pomocou bilineárnej interpolácie
- náhodné javy (horizontálne preklopenie, zmeny jasu, kontrastu a sýtosti, rotácia, orezanie a zmena veľkosti obrázka)
- normalizácia pomocou vypočítaných z trénovaného datasetu priemeru a štandardnej odchýlky



# Technológie finálneho modelu

- Reziduálne bloky – znížiť problém miznutia gradientov počas a urýchliť tréningový proces.
- Augmentácia dát – pomáha prekonať triednu nevyváženosť a overfitting.
- Learning rate scheduler – nám umožnil dynamicky obmedziť rýchlosť učenia, čo nám pomáha vyhnúť sa „prekročeniu“ optimálnych hodnôt.
- Gradient clipping – zabraňuje príliš veľkým zmenám váh modelu spôsobených gradientovou explóziou.
- Regularizácia s úbytkom vah – aby obmedziť rast váh a zabrániť nadmernému prispôbaniu modelu.
- Batch normalizácia – pomáha znižovať vnútorný posun kovariát a urýchľuje tréningový proces.
- Dropout – pomáha predchádzať nadmernému vybaveniu náhodným vypadávaním jednotiek počas tréningovania.
- Focal loss funkcia – pomáha s nevyváženými dátami s ťažko zaraditeľných objektoch.



# Experimenty s finálnym modelom

Väčší batch size -> lepšie výsledky.

10 epoch.

Dobrý dropout probability by mohol výrazne znížiť pretrénovanie.

Gradient clipping aby zabránil „explodujúcemu“ gradientu.

Najlepší počet snímkov je od 34 do 45.

TABLE II: Comparison of results using different dropout probabilities

D. prob.	0.4	0.5	0.6	0.7
<b>Loss</b>	0.00675014	0.00705843	0.00813567	0.00866412
<b>Accuracy</b>	0.8258	0.7197	0.7197	0.2197
<b>Precision</b>	0.5714	0.3125	0.3800	0.1953
<b>Recall</b>	0.3200	0.4000	0.7600	1.0000
<b>F1</b>	0.4103	0.3509	0.5067	0.3268
<b>Specificity</b>	0.9439	0.7944	0.7103	0.0374

TABLE III: Comparison of results using different gradient clipping

Grad. clip.	0.1	0.4	0.5	0.8
<b>Loss</b>	0.00813567	0.00748908	0.00851292	0.00772153
<b>Accuracy</b>	0.7197	0.7576	0.7121	0.7197
<b>Precision</b>	0.3800	0.4386	0.3617	0.3636
<b>Recall</b>	0.7600	1.0000	0.6800	0.6400
<b>F1</b>	0.5067	0.6098	0.4722	0.4638
<b>Specificity</b>	0.7103	0.7009	0.7196	0.7383




# Konečné výsledky

Väčšia veľkosť testovacieho setu.

Prijateľné výsledky klasifikácie.

Vysoký recall.



Hyperparametre:

Number of frames	45
Learning rate	0.001
Weight decay	0.001
Shed epochs	16
Gradient clipping	0.4
Batch size	20
Dropout probability	0.65
Gamma	1
Alpha	0.8

Loss a metriky:

Loss	0.00454302
Accuracy	0.6700
Precision	0.3556
Recall	0.8000
F1	0.4923
Specificity	0.8000



# Komplikované veci a problémy

- Nevyvážený dataset
- Ťažko viditeľný rozdiel medzi triedami
- Rýchle pretrénovanie
- Náročné na grafickú pamäť modely



## Ďalší pokrok

- Rozšírenie tréovacích dát.
- Ladenie hyperparametrov pre presnejšie výsledky.
- Skúmanie techník na identifikáciu špecifických oblastí vo videách z ultrazvuku (cenné poznatky a zlepšiť interpretovateľnosť predikcií modelu).



# Záver

- Krok vpred v automatizovanej detekcii klížu pľúc pomocou hlbokého učenia.
- Riešenie na detekciu klížu pľúc na ultrazvuku.
- Výskum dal nám veľa skúseností s používaním rôznych technológií pri práci s CNN, s nezbalansovaným datasetom, video dátami, a medicínskymi nuansami.
- Toto úsilie by mohlo viesť k ešte presnejším a spoľahlivejším systémom automatickej detekcie pneumothoraxu a iných hrudných ochorení.



## Pod'akovanie

Ing. Maroš Hliboký, ďakujeme za poradenstvo a pomoc pri výskume.

Taktiež by sme sa chceli poďakovať Technickej univerzite v Košiciach za poskytnutie prístupu ku GPU počas trvania výskumu.